Pharsight V1 进展汇报

FinSight 反思、技术闭环与能力边界

Pharsight 项目组

2026 年 9 月 23 日

提纲

1. 项目定位与 V1 范围
2. FinSight 运行反思与应对
3. Pharsight 技术进展
4. 能力边界与分析
5. 后续任务与结论

一、项目定位与 V1 范围

项目定位

使命

基于 FinSight 多智能体，建设可复现的 A/H 医药投研系统，服务高校研究与演示。

- 两种模式：医药行业研究、上市医药公司研究
- 中文输出，全球临床、监管与文献作为补充证据
- 全链路保留来源、日期、口径与定位
- 仅作投研辅助，不构成投资或医疗建议

基线约束

- 上游：RUC-NLPIR/FinSight
- 固定提交：`8fc5bce`；许可证 GPL-3.0
- 标准运行时：Python 3.11
- `FinSight/` 只读，改动限于 `pharsight/`

最新状态

2026-09-21

- 双模式配置、受控清单、四层提示词、中文大纲、精确引用
- 42 项无网络单元测试通过
- 尚未使用真实语料端到端运行

2026-09-22

- 恒瑞医药 189 页年报整本 OCR，489 个页级文本块持久索引
- 七类研究任务分别检索，页码与块号进入 Memory
- 生成 11 节公司研报（86,884 字节），严格引用通过
- 75 项定向测试通过（Python 3.12.7）

未验收：Python 3.11 标准环境、多来源覆盖、行业模式、医药领域人工复核。

V1 范围

目标

保留 FinSight 共享 Memory 与三段式编排，逐步实现医药投研流程：研究任务书 → *DataCollector* 采集 → *DataAnalyzer* 分析 → *ReportGenerator* 生成 → 发布校验

已完成

- 双模式配置与领域提示词
- 受控清单与网页 PDF 证据
- PDF 解析、分页分块与任务检索
- 精确引用与失败关闭

未纳入

- 不替换 Memory 与编排
- 不引入图数据库或新 RAG 框架
- 不宣称多来源覆盖或发布级质量
- 图表、估值与行业模式后置

二、FinSight 运行反思与应对

四次真实运行

运行	时间	对象	主要结果
首跑	09-18	九安医疗（金融模式）	40 min；采集 0/12；引用错误；进程未退出
重跑	09-20	同上，授权修复后	16 min；ERROR 122→0；跨主体污染；未退出
调试闭环	09-22	恒瑞医药年报前 20 页	三章节报告；退出码 0；严格引用通过
完整闭环	09-22	恒瑞医药 189 页年报	489 块索引；任务检索；11 节报告

证据口径

结论分源码事实、运行实证与推断三类；全部绑定上游基线 `8fc5bce`，证据来自日志、产物与检查点。

首跑量化结果（2026-09-18）

指标	结果
采集任务	12/12 保存 0 条数据（DSML 协议不兼容）
点击动作	启动 124 / 成功 2 / 失败 123（含下标越界 122 次）
代码执行	超时 14 次（每次 120 秒）
报告引用	18 条，含错误主体与无关来源
报告图表	3 张；图片耗尽告警 21 次
进程与合规	未退出超过 45 分钟；缺少免责与非医疗建议声明
总体判断	形式完整，证据链不成立

首跑：失效环节与可复用组件

五项失效

1. 采集：DSML 被误判为最终答案，任务一轮终止
2. 抓取：空结果下标越界；以搜索摘要替代原文
3. 引用：自由文本来源，无主张映射
4. 运行时：嵌套 `asyncio.run` 与不可取消线程，进程无法退出
5. 合规：缺少免责与非医疗建议声明

可复用组件

- 编排：优先级分组、并发、检查点续跑
- 共享 Memory 跨阶段传递
- 代码执行器内确定性计算
- LLM 重试与上下文降级
- 模板化大纲与写作

判断：编排与写作可复用；证据链各环节需重建。

授权修复（2026-09-20）

可观测性与治理

- 点击空结果显式化
- 抓取逐 URL 记录异常
- 异步桥替代嵌套 *asyncio*
- 执行器线程回收
- 引用实体校验与 *citation_audit*

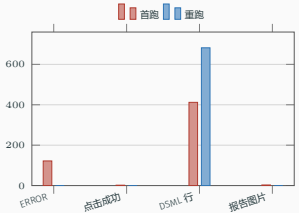
协议与内容护栏

- 动作协议归一化与失败关闭
- 提示词去实体化与实体 lint
- 图表占位与路径修复
- 退出兜底与 UTF-8 日志
- 引用去重与来源分级

改动文件语法编译通过；*FinSight* HEAD 未变，Git 索引无变更。

重跑对比

指标	首跑	重跑
运行时长	≈40 min	≈16 min
ERROR 数	122	**0**
点击成功/尝试	2/124	0/18
采集保存	12×0	12×0
含 DSML 行	412	682
引用审计（解/未/拒）	无能力	129/2/3
引用错误主体	有	无
报告图片	3	0
跨主体污染	未发现	有（BYD 整章）
进程退出	异常	异常



ERROR 归零；点击与图表仍为 0；DSML 增加（协议修复晚于重跑）。

架构讨论摘要（讨论 1–7）

主题	结论
调用机制	BaseAgent 为统一动作循环，调度硬编码；工具与 Agent 返回形状不一致，异常吞并为空
数据链路	search/click 白名单；正文截断 6000 字符，PDF 无页码；来源约束仅存在于提示词
预处理	无确定性清洗与口径归一，过程不可复现
迭代结构	六层嵌套，L1 为主引擎；结束条件隐式
去重与缓存	Memory 仅追加；resume 命中旧检查点直接返回缓存
评测体系	论文 9 项指标、单一 LLM 评委、相对分数，非 claim 级核验
黄金报告	券商二手来源、单一锚、许可受限；事实须回到一手来源

反思总表（一）：接口与编排

问题（证据）	应对与状态
XML 协议不兼容原生调用格式（DSML、代码围栏、空 *execute*），静默终止（采集 0/12）	协议归一化与未知格式失败关闭（已实现）
工具与 Agent 返回形状不一致，无参数 schema，异常吞并	兼容真实返回形态，证据规范化（已实现）
固定三段式，无问答入口	保留主干，问答后置（计划）
resume 与实例复用返回旧缓存	显式 *--resume*，修复状态语义（部分）
异步客户端跨事件循环复用	独立客户端工厂与桥接取消（已实现）
结束条件隐式，轮次存在偏差	完成标记与失败关闭（部分）

反思总表（二）：采集与抓取

问题（证据）	应对与状态
空结果下标越界（122 次）	空结果与错误显式化（已修复）
抓取失败静默返回空列表；环境未预检	逐 URL 异常记录；启动预检（部分）
正文截断 6000 字符；PDF 无页码、扫描件无 OCR	整本 OCR、分页分块与页级检索（已实现）
搜索摘要即证据，未打开链接可被引用	来源分级、精确证据 ID 与引用校验（部分）
附件直链不在白名单，模型改猜本地清单	附件确定性提取与类型、报告期校验（已实现）
超时后改页数重复提交 OCR	完整缓存、任务续查（ADR-011，已实现）
年报与业绩材料混淆；域名归属未验证	文档类型与报告期校验（已实现）；发布者归属（待办）

反思总表（三）：引用与报告

问题（证据）	应对与状态
引用为自由文本，无主张映射；错误主体与无关来源	精确证据 ID、实体校验、*citation_audit*（已实现）
模型重编号或本地化来源编号（*S001*、*[来源:WEB-*]*）	仅精确别名归一化，未知编号阻断（ADR-013，已实现）
提示词示例泄漏（BYD 整章）	示例去实体化与生成后实体 lint（已实现）
图表链路断裂：0 图、虚构 *@import*、占位文本	占位与路径修复；Pharsight 暂关图表（部分）
调试大纲被模型从 3 章扩为 13 章	受控直接大纲（已实现）
章节停在半句或工具动作仍记为完成	完整性门禁、失败重试与润色回退（ADR-014，已实现）
报告缺少免责与非医疗建议声明	强制声明注入（已实现）

反思总表（四）：运行时与评测

问题（证据）	应对与状态
嵌套 *asyncio.run* 与不可取消线程导致孤儿任务、进程未退出	异步桥、daemon 线程与回收（部分）；看门狗待做
Windows GBK 控制台编码错误	UTF-8 文件日志与可逆转义（已实现）
长对话历史无上限，上下文溢出	单条截断、历史预算与失败取消（已实现）
配置落盘包含密钥	落盘前递归遮蔽（已实现）
费用与时延不可控	受控配置、单并发与完整缓存（部分）
评测为单一 LLM 评委、相对分数、非 claim 级	claim 级引用、一手裁定与专家盲评（规划）
黄金报告为二手单一锚且许可受限	仅作呈现基准；事实回到一手来源（原则）

失败模式归因

五类失败模式

1. **协议刚性**：文本协议与模型原生调用生态脱节
2. **状态语义模糊**：复用与缓存导致检索缺失或重复
3. **证据软约束**：来源依赖提示词自律，缺少逐条核验
4. **运行时隔离不足**：嵌套事件循环与不可取消线程
5. **验收门禁缺位**：任务完成不等于产物完整

应对原则

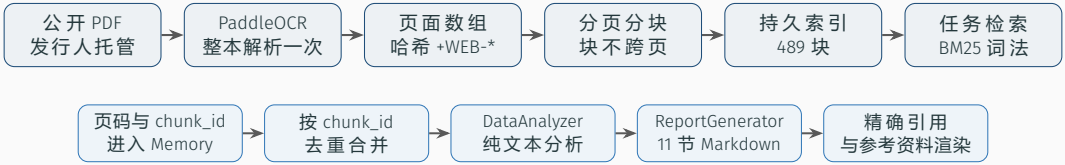
- 软约束转为确定性闸门：引用、截止日、完整性、声明
- 不可观测失败转为显式失败关闭
- 不可定位证据转为父来源加页/块定位
- 复用可验证组件，避免重复造基础设施

三、Pharsight 技术进展

进度时间线

日期	阶段	里程碑
09-21	纵向切片	双模式配置、清单工具、四层提示词、中文大纲、精确引用；42 项测试
09-22 上午	最小闭环	网页证据 *WEB-**；PDF 解析；三章节报告；75 项测试
09-22 晚	完整闭环	189 页整本解析与缓存；489 块索引；任务检索；11 节报告；ADR-010 ～ 014

完整 PDF 技术闭环



整本仅解析一次；分析与提示词不注入全文；引用始终保留父来源编号与页码定位。

PDF 解析、分块与索引

解析与缓存

- 始终请求完整文档，*max_pages* 仅裁剪预览
- 完整结果缓存与超时任务续查
- 缓存键基于来源 URL，索引身份包含内容哈希
- 缓存与索引位于忽略目录

分块与索引

- 块长 1,800 字符、重叠 240，不跨页
- 保留文档哈希、*chunk_id*、页码、章节标题
- *chunk_id* 支持稳定去重与回查
- 索引清单记录总页数与总块数

安全边界：限制私网、重定向与 50 MB；凭据仅取自环境变量；文本 PDF 回退 *pdfplumber*。

任务检索与 Memory 契约

PDF evidence search

- 以研究问题为参数，可限定父来源与 *top_k*
- 确定性 BM25、同义扩展、短语加分、单页上限
- 返回块号、页起止、章节标题、文本与分数
- 本轮命中覆盖第 5–181 页多段（含 104–105、140–181）

Memory 合并

- 首次解析仅写入索引摘要
- 按父 *source_id* 合并、按 *chunk_id* 去重
- 保留页码定位并更新已批准证据
- 报告引用父来源，定位依赖页码与块号

限制：词法检索对同义词、表格与 OCR 错字召回有限；重大事实须回看原 PDF。

实跑验收（2026-09-22，恒瑞医药）

检查项	结果	证据
整本文档解析	通过	189 页，缓存复用
分页分块	通过	489 块，不跨页
后部页面可检索	通过	104–105、140–181 页
任务级检索	通过	七类采集问题
来源身份稳定	通过	*WEB-56697731BB*
块去重	通过	按 *chunk_id* 合并
完整公司报告	通过（技术）	11 节闭合，86,884 B
精确引用	通过（程序）	未知编号阻断

未验收

Python 3.11 环境、多来源覆盖、医药领域正确性、行业模式。

同日调试闭环

恒瑞前 20 页、三章节、退出码 0、严格引用通过、75 项测试与 Ruff 通过。

架构决策（ADR-010 ～ 014）

编号	主题	决定
ADR-010	PDF 接入边界	公开 PDF 沿用 Click 边界；优先 PaddleOCR，文本 PDF 回退；限私网、重定向与体积
ADR-011	缓存与续查	完整结果缓存、超时续查、不同页数复用，避免重复计费
ADR-012	分块与词法检索	块不跨页；向量、图后端复用同一结果字段
ADR-013	精确别名归一化	仅允许集合内的精确别名可修复；未知编号仍阻断发布
ADR-014	章节完整性门禁	完成标记、长度与闭合检查；润色失败保留已验证草稿

四、能力边界与分析

能力边界

已经证明

单份长 PDF 可不漏页进入可检索索引；任务检索可召回后部页面证据；完整章节报告与精确引用可技术闭环；协议、引用与完整性失败可显式关闭。

尚未证明

单一年报不足以支撑临床、监管、支付、竞争与行情结论；OCR 对复杂表格与脚注可能丢结构；词法检索召回有限；Memory 单轮约 6.5 MB；域名归属未验证；报告不构成发布级研报。

判断

项目已由“流程可实现”进入“证据可定位、引用可审计”阶段；下一门槛是多来源覆盖、固定评测与领域复核。

向图检索演进

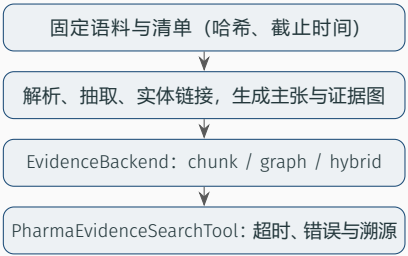
稳定入口

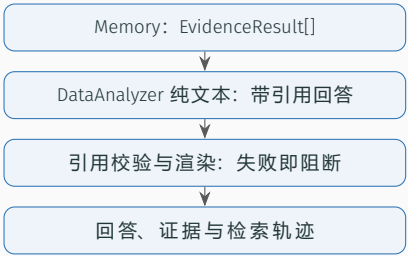
- *Document*：*document_hash* 与父 *source_id*
- *Page*/*Chunk*：页码与 *chunk_id*
- 信息抽取生成 *Entity*、*Event*、*Claim*
- *Claim -[SUPPORTED_BY]-> Chunk* 保留原文与页码

演进约束

- 图、向量与 Hybrid 复用 *retrieval_hits* 字段
- 生成器不感知底层检索
- 切换后端前建立固定查询集
- 对照 Recall@K、定位正确率、重复率、引用完整率、延迟与成本
- 不以“更先进”替换可解释基线

RAG V1 目标架构





原则：证据优先、后端可替换、生成器无图感知、失败可见、快照可复现、候选主张不等同事实。

检索策略与评测设计

检索策略

- Chunk 基线：Passage 索引、截止日与实体过滤、top-k
- Graph：种子命中后 1–2 跳扩展；仅采纳已批准主张
- Hybrid：种子、图扩展、去重、门控与重排
- 策略切换仅改配置与后端

评测指标与假设

- 召回与精确：Recall@k、Precision@k
- 引用质量：有效率、支持率、覆盖率
- 比较与冲突：跨文档覆盖率、冲突识别率
- 定位与成本：页码正确率、延迟
- H1–H4：图收益、错引下降、封装解耦、样本充分性

五、后续任务与结论

分阶段完成度

阶段	名称	完成标准	状态
0	固定案例	1 公司/1 资产/1 适应症，5–10 份一手资料与截止日	部分
1	模式与提示词	双模式全流程识别，不回退通用模板	公司模式完成
2	受控证据包	清单、网页 PDF、截止日过滤与来源编号	完成
3	主流程	完整 PDF、页级索引、任务检索、11 节报告	技术闭环
4	质量闸门	引用、日期、完整性与声明程序校验	程序完成，人工待办
5	在线数据	交易所、CDE/NMPA、ClinicalTrials、PubMed、医保/集采，再做行业模式	下一步
6	自动化	自动任务、实时检索、图表、稳定导出、图检索	后置

任务与风险

当前任务

- V1-005 待审：11 节报告已生成，多来源与领域验收未完成
- V1-006 进行中：程序校验完成，人工复核待办
- V1-007/009 待审或进行中：证据选择、搜索到 PDF 路由
- V1-008/010 待审：OCR 工具与页级索引已验证

主要风险

- 词法检索召回有限
- Memory 随任务检索持续增长
- 域名归属与来源等级未验证
- 章节完整性需持续回归
- Python 3.11 与依赖锁定

结论

1. FinSight 三次运行暴露五类失败模式：协议、状态、证据、运行时与验收门禁；编排与写作可复用
2. Pharsight 已实现 189 页年报至 11 节报告的技术闭环，75 项定向测试通过
3. 能力边界明确：多来源、行业模式、Python 3.11 与领域正确性尚未验收
4. 后续先补多来源与评测，再推进向量、图与 Hybrid 对照

下一步

Python 3.11 复现；接入交易所、CDE/NMPA、ClinicalTrials、PubMed、医保/集采与行情；建立问题到相关页标注集；增加证据预算与惰性读取；完成人工领域复核。

本汇报不代表医学审评或发布级证券研究能力，不构成投资或医疗建议。

相关文档（pharsight/docs/v1/）

- 方案：*PHARMA_RAG_V1.md*、*PHARMA_RESEARCH_WORKFLOW_AND_FINSIGHT_ADAPTATION.md*
- 实现与验收：*IMPLEMENTATION_SUMMARY_2026-09-21.md*、*REPORT_RUN_DEBUG_2026-09-22.md*、*FULL_PDF_RETRIEVAL_AND_REPORT_2026-09-22.md*
- 反思：*DESIGN_DISCUSSION_LOG.md*、*FINSIGHT_RUN_REVIEW_2026-09-18.md*、*FINSIGHT_RERUN_REVIEW_2026-09-20.md*
- 管理：*README.md*、*PROJECT_MANAGEMENT.md*、*ARCHITECTURE.md*

谢谢，欢迎讨论