Pharsight V1 进展汇报

FinSight 反思与 Pharsight 进展

Pharsight 项目组

2026 年 9 月 23 日

项目定位与目标

- Pharsight：基于 FinSight 的 A/H 医药投研智能体，面向高校研究与演示
- 两种模式：医药行业研究、上市医药公司研究；中文输出
- 仅作投研辅助，不构成投资或医疗建议

V1 目标

保留 FinSight 三段式主干，实现受控、可审计的医药投研流程：研究任务书 → 采集 → 分析 → 报告 → 发布校验

- 上游基线 `8fc5bce`；标准运行时 Python 3.11

FinSight 实测：四次运行

时间	运行	主要结果
09-18	九安医疗首跑	采集 0/12；引用错误；进程未退出
09-20	修复后重跑	错误归零；抓取仍失败；出现跨主体污染
09-22	恒瑞年报调试	三章节报告闭环，退出码 0
09-22	恒瑞 189 页完整运行	489 块页级索引；11 节报告

结论

编排与写作可复用；证据链各环节需要重建。

FinSight 实测：五类问题

1. 协议：不兼容模型原生调用格式，任务静默终止
2. 状态：缓存与复用导致检索缺失或重复
3. 证据：来源为自由文本，无定位与主张映射
4. 运行时：嵌套事件循环导致进程无法退出
5. 质量：任务完成不等于产物完整，缺少必要声明

可复用部分

编排与检查点、共享 Memory、确定性计算、模板化写作。

对 Pharsight 的设计启示

- **精确引用**：只允许真实来源编号，未知引用阻断发布
- **完整证据**：原文整本解析、分页分块，保留父来源与页码定位
- **失败关闭**：协议、截止日、章节完整性与声明的确定性校验
- **保留主干**：不替换编排，检索后端可替换

Pharsight 进展：完整 PDF 技术闭环

已完成

- 医药双模式配置、受控清单、领域提示词与中文大纲
- 真实 189 页年报：整本 OCR、489 块页级索引
- 七类研究任务分别检索，页码随证据进入 Memory
- 11 节公司研报，严格引用通过
- 75 项定向单元测试通过

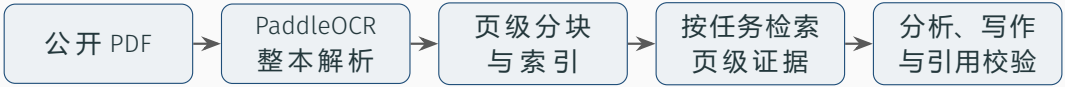
未验收

Python 3.11 标准环境、多来源覆盖、行业模式、医药领域人工复核。

样例

恒瑞医药 600276.SH；报告 86,884 字节；来源编号 *WEB-56697731BB*。

技术闭环



- 整本仅解析一次；分析与提示词不注入全文
- 引用保留父来源编号，事实定位使用页码与块号

能力边界

已经证明

长 PDF 证据可定位、引用可审计，报告生成可技术闭环。

尚未证明

单一年报不足以支撑完整投研结论；OCR 与词法检索存在局限；报告不是发布级研报。

判断

项目已从“流程可实现”进入“证据可定位、引用可审计”阶段；下一门槛是多来源覆盖与领域复核。

下一步

1. 在 Python 3.11 干净环境复现
2. 接入更多一手来源：交易所、CDE/NMPA、ClinicalTrials、PubMed、医保/集采
3. 建立固定问题—相关页标注集，量化检索召回
4. 完成医药与证券领域人工复核

详见 *pharsight/docs/v1/*：设计讨论记录、两次运行复盘、实现说明与完整 PDF 验收记录。

谢谢，欢迎讨论